

Efecto de la transformación de Box–Cox en la segmentación de grietas

Este informe resume el efecto de la transformación de Box–Cox como prefiltrado en la segmentación de grietas, evaluado sobre cuatro conjuntos de imágenes según la geometría de la fractura. Se reportan los datos, la metodología y los resultados, con énfasis en cómo la transformación **mejora la capacidad de detección de la grieta** (*recall*) y en el compromiso resultante con la *precision*.

1. Datos

Utilicé el conjunto de grietas de hormigón de Özgenel & Sorguç. Seleccioné **cuatro conjuntos de 50 imágenes** según la geometría de la fractura: **verticales**, **horizontales**, **oblicuas** (de izquierda a derecha) y **grandes** (la grieta ocupa una porción amplia de la imagen). Cada imagen RGB tiene su máscara binaria (grieta *vs.* fondo). Todas se redimensionaron a 256×256 y la máscara se binarizó. En total, $4 \times 50 = 200$ imágenes etiquetadas.

2. Metodología

Prefiltrado Box–Cox. Cada imagen se convierte a escala de grises ($0,299R+0,587G+0,114B$), se le aplica la transformación de Box–Cox con λ estimado por máxima verosimilitud y luego un *histogram stretching* a $[0,1]$. La transformación es **por imagen** (cada una con su propio λ). Comparo dos condiciones: **sin** Box–Cox (intensidad gris cruda) y **con** Box–Cox.

Clasificadores. Cinco métodos clásicos a nivel de píxel: SVM (RBF), LightGBM, KNN, LDA y QDA. La *feature* es la intensidad del píxel. **Protocolo por imagen:** para cada imagen se entrena con una muestra estratificada de sus píxeles y se predice la imagen completa, siguiendo el protocolo del artículo original.

Métricas (clase grieta): IoU, Dice/F1, *Precision* y *Recall*. Reporto **media $\pm$ desviación estándar sobre las 50 imágenes** de cada conjunto. La *Accuracy* se omite por ser engañosa (la grieta es $\sim 1\%$ de los píxeles).

Significancia. Para cada comparación con/sin Box–Cox uso un **test pareado de permutación** (sign-flip) y el de Wilcoxon, ambos pareando imagen con imagen, más **intervalos de confianza al 95 % por bootstrap**. El bootstrap es válido aquí porque se remuestran *imágenes* (observaciones independientes), no píxeles de una misma imagen (que presentan autocorrelación espacial). Significancia: $*p < 0,05$, $**p < 0,01$, $***p < 0,001$.

3. Resultados

Table 1: Calidad global de la segmentación de la grieta: IoU y Dice (F1), media $\pm$ desv. est. sobre las 50 imágenes de cada conjunto. Δ = con – sin Box–Cox (puntos porcentuales).

Método	IoU (%)			Dice (%)		
	sin BC	con BC	Δ	sin BC	con BC	Δ
<i>Verticales</i> ($\bar{\lambda} = 2.17$)						
SVM	37.8 $\pm$ 13.0	36.7 $\pm$ 12.7	–1.1***	53.6 $\pm$ 14.2	52.4 $\pm$ 14.1	–1.2***
LightGBM	29.4 $\pm$ 11.5	29.3 $\pm$ 11.4	–0.1	44.3 $\pm$ 13.4	44.2 $\pm$ 13.3	–0.1
KNN	24.7 $\pm$ 11.0	24.7 $\pm$ 11.0	+0.0	38.4 $\pm$ 13.4	38.5 $\pm$ 13.4	+0.1
LDA	41.3 $\pm$ 16.1	32.9 $\pm$ 13.6	–8.4***	56.6 $\pm$ 17.2	48.0 $\pm$ 16.1	–8.7***
QDA	39.0 $\pm$ 17.4	37.6 $\pm$ 16.5	–1.4	53.7 $\pm$ 19.6	52.4 $\pm$ 19.0	–1.3
<i>Horizontales</i> ($\bar{\lambda} = 1.73$)						
SVM	32.6 $\pm$ 10.2	32.2 $\pm$ 9.9	–0.4***	48.3 $\pm$ 11.6	47.9 $\pm$ 11.3	–0.4***
LightGBM	26.8 $\pm$ 9.6	26.7 $\pm$ 9.2	–0.1	41.4 $\pm$ 11.8	41.3 $\pm$ 11.4	–0.1
KNN	21.5 $\pm$ 7.3	21.5 $\pm$ 7.3	+0.0	34.8 $\pm$ 9.7	34.8 $\pm$ 9.7	+0.0
LDA	34.9 $\pm$ 12.9	29.8 $\pm$ 10.2	–5.1***	50.4 $\pm$ 14.4	45.0 $\pm$ 11.9	–5.4***
QDA	32.2 $\pm$ 15.9	34.6 $\pm$ 13.3	+2.4*	46.4 $\pm$ 20.2	49.9 $\pm$ 16.2	+3.5**
<i>Oblicuas (izq. $\rightarrow$ der.)</i> ($\bar{\lambda} = 2.11$)						
SVM	37.4 $\pm$ 12.2	36.4 $\pm$ 11.6	–1.1***	53.3 $\pm$ 13.4	52.3 $\pm$ 13.0	–1.1***
LightGBM	30.4 $\pm$ 10.7	30.5 $\pm$ 10.7	+0.1	45.5 $\pm$ 13.0	45.7 $\pm$ 12.9	+0.1
KNN	23.9 $\pm$ 8.7	23.9 $\pm$ 8.7	–0.0	37.8 $\pm$ 11.5	37.8 $\pm$ 11.5	–0.0
LDA	40.7 $\pm$ 17.1	29.5 $\pm$ 12.0	–11.2***	55.7 $\pm$ 18.5	44.2 $\pm$ 14.4	–11.4***
QDA	41.0 $\pm$ 16.3	39.0 $\pm$ 13.2	–2.1	56.1 $\pm$ 18.2	54.8 $\pm$ 14.3	–1.4
<i>Grandes</i> ($\bar{\lambda} = 2.38$)						
SVM	32.5 $\pm$ 10.5	31.5 $\pm$ 9.9	–1.0***	48.1 $\pm$ 12.4	47.0 $\pm$ 11.9	–1.1***
LightGBM	25.8 $\pm$ 7.7	25.8 $\pm$ 7.8	–0.1	40.5 $\pm$ 9.7	40.4 $\pm$ 9.7	–0.1
KNN	20.5 $\pm$ 6.1	20.4 $\pm$ 6.1	–0.1**	33.6 $\pm$ 8.1	33.5 $\pm$ 8.1	–0.1**
LDA	36.2 $\pm$ 11.9	25.0 $\pm$ 8.9	–11.3***	52.1 $\pm$ 13.2	39.2 $\pm$ 11.2	–12.9***
QDA	37.6 $\pm$ 10.8	33.1 $\pm$ 11.2	–4.4***	53.7 $\pm$ 11.6	48.7 $\pm$ 12.8	–5.0***

Table 2: Compromiso *precision–recall* para la clase grieta, media $\pm$ desv. est. sobre 50 imágenes. $\Delta =$ con – sin Box–Cox.

Método	Precision (%)			Recall (%)		
	sin BC	con BC	Δ	sin BC	con BC	Δ
<i>Verticales</i> ($\bar{\lambda} = 2.17$)						
SVM	47.8 $\pm$ 14.6	45.8 $\pm$ 14.2	−1.9***	63.2 $\pm$ 15.0	63.6 $\pm$ 15.2	+0.5***
LightGBM	33.9 $\pm$ 12.5	33.8 $\pm$ 12.4	−0.1	67.4 $\pm$ 14.7	67.4 $\pm$ 14.6	+0.0
KNN	27.0 $\pm$ 11.6	27.1 $\pm$ 11.6	+0.1	70.8 $\pm$ 12.9	70.8 $\pm$ 13.0	+0.0
LDA	58.2 $\pm$ 21.1	42.6 $\pm$ 19.7	−15.6***	59.0 $\pm$ 12.9	64.5 $\pm$ 16.1	+5.5***
QDA	74.6 $\pm$ 21.8	61.3 $\pm$ 23.4	−13.3***	45.6 $\pm$ 19.1	53.7 $\pm$ 21.5	+8.1***
<i>Horizontales</i> ($\bar{\lambda} = 1.73$)						
SVM	43.0 $\pm$ 12.0	42.3 $\pm$ 11.8	−0.7***	57.1 $\pm$ 13.5	57.3 $\pm$ 13.6	+0.2***
LightGBM	32.3 $\pm$ 11.1	32.2 $\pm$ 10.7	−0.1	60.4 $\pm$ 13.0	60.4 $\pm$ 13.1	−0.0
KNN	24.3 $\pm$ 7.9	24.3 $\pm$ 7.9	+0.0	63.8 $\pm$ 12.2	63.8 $\pm$ 12.3	+0.0
LDA	48.5 $\pm$ 17.4	39.3 $\pm$ 14.1	−9.2***	54.7 $\pm$ 11.7	57.6 $\pm$ 14.6	+2.9***
QDA	77.8 $\pm$ 10.6	63.5 $\pm$ 17.3	−14.3***	37.0 $\pm$ 19.6	46.4 $\pm$ 19.8	+9.4***
<i>Oblicuas (izq. $\rightarrow$ der.)</i> ($\bar{\lambda} = 2.11$)						
SVM	48.4 $\pm$ 14.8	46.4 $\pm$ 13.9	−2.0***	61.7 $\pm$ 13.9	62.2 $\pm$ 14.1	+0.5***
LightGBM	36.1 $\pm$ 12.7	36.3 $\pm$ 12.6	+0.2	65.2 $\pm$ 13.4	65.0 $\pm$ 13.6	−0.2
KNN	26.5 $\pm$ 9.5	26.5 $\pm$ 9.5	−0.0	69.5 $\pm$ 11.0	69.5 $\pm$ 11.0	−0.0
LDA	56.6 $\pm$ 24.4	36.5 $\pm$ 17.0	−20.1***	59.1 $\pm$ 11.1	64.2 $\pm$ 14.2	+5.1***
QDA	78.8 $\pm$ 19.9	61.3 $\pm$ 19.8	−17.4***	45.9 $\pm$ 17.2	55.5 $\pm$ 17.6	+9.6***
<i>Grandes</i> ($\bar{\lambda} = 2.38$)						
SVM	42.2 $\pm$ 15.5	40.2 $\pm$ 14.5	−2.0***	63.7 $\pm$ 12.1	64.2 $\pm$ 12.1	+0.6***
LightGBM	30.3 $\pm$ 9.8	30.2 $\pm$ 9.8	−0.1	66.9 $\pm$ 10.7	67.0 $\pm$ 10.7	+0.0
KNN	22.4 $\pm$ 6.9	22.3 $\pm$ 6.9	−0.1**	71.0 $\pm$ 7.2	71.0 $\pm$ 7.1	+0.0*
LDA	52.4 $\pm$ 18.9	30.6 $\pm$ 14.3	−21.8***	56.3 $\pm$ 8.3	65.2 $\pm$ 11.0	+8.9***
QDA	67.9 $\pm$ 17.0	48.1 $\pm$ 19.1	−19.9***	46.4 $\pm$ 10.7	58.2 $\pm$ 13.5	+11.8***

4. Efecto de la transformación: mejora del *recall*

El efecto de Box–Cox es **sistemático y coherente en los cuatro conjuntos**: al estirar el contraste de los píxeles oscuros de la grieta, la transformación **realza la fractura respecto del fondo** y el clasificador **reconoce más píxeles que realmente son grieta**. En consecuencia, el ***recall* aumenta de forma significativa** en todos los conjuntos (menos falsos negativos): mejora la capacidad de *detectar* la fractura. El costo es una caída de la *precision* (más fondo etiquetado como grieta), por lo que el resultado neto es el clásico **compromiso *precision–recall***: se gana sensibilidad de detección a cambio de una localización más gruesa de la grieta.

El tamaño del efecto depende del método:

- **LDA y QDA** (sensibles a la distribución, pues asumen normalidad) muestran el efecto más marcado: el *recall* sube entre +5 y +12 puntos, pero la *precision* cae aún más (entre −9 y −22 puntos). Como la pérdida de *precision* domina, el **IoU y el Dice empeoran**.
- **SVM** muestra un cambio pequeño en la misma dirección ($\sim +0,5$ de *recall*, ~ -2 de *precision*); IoU/Dice bajan levemente.
- **LightGBM y KNN** son prácticamente **invariantes** ($\Delta \approx 0$), como cabe esperar de métodos

insensibles a transformaciones monótonas de una sola *feature*.

5. Ejemplos

Un ejemplo por tipo de grieta (clasificador QDA). De izquierda a derecha: imagen RGB, máscara real y segmentación *sin* y *con* Box-Cox. Con la transformación el modelo reconoce más píxeles de grieta (mayor *recall*); en el caso oblicuo, sin Box-Cox no se detecta nada y la transformación lo *rescata*.




Figure 1: Grieta vertical.




Figure 2: Grieta horizontal.




Figure 3: Grieta oblicua (caso de rescate: sin Box-Cox no se detecta nada).




Figure 4: Grieta grande.

6. Resultados por tipo de grieta

- **Verticales:** Box-Cox aumenta el *recall* de QDA (+8,1) y LDA (+5,5), pero la caída de *precision* (−13,3 y −15,6) reduce el IoU (LDA −8,4; QDA −1,4, no significativo). El resto sin cambios relevantes.
- **Horizontales:** *Único caso favorable.* En QDA, el fuerte aumento de *recall* (+9,4) compensa la pérdida de *precision* y el **IoU sube +2,4 y el Dice +3,5** (significativos, $p < 0,05$). LDA sigue empeorando (−5,1).
- **Oblicuas:** comportamiento similar a verticales; LDA es el más perjudicado (IoU −11,2, *precision* −20,1) pese a ganar *recall* (+5,1).
- **Grandes:** el **caso más desfavorable.** LDA (IoU −11,3) y QDA (IoU −4,4) caen claramente: aunque el *recall* sube mucho (QDA +11,8), la *precision* se desploma (−21,8 y −19,9).

7. Conclusión

Sobre un conjunto de prueba amplio (50 imágenes por tipo, con medidas de incertidumbre y tests pareados), Box-Cox **mejora la detección de la grieta**: aumenta el *recall* de forma significativa en los cuatro tipos, especialmente en los clasificadores sensibles a la distribución (LDA y QDA), e incluso **rescata** casos en que sin la transformación el modelo no detecta nada. El contrapeso es una pérdida de *precision*: la región predicha se engrosa e incorpora fondo, por lo que en agregado el IoU y el Dice pueden bajar (salvo QDA en grietas horizontales, donde el balance es favorable). La transformación es, por tanto, especialmente útil cuando la prioridad es **no pasar por alto la fractura** (maximizar *recall*); si se requiere una delimitación más fina, conviene combinarla con un post-procesamiento que recupere *precision*. Los métodos basados en árboles o vecinos (LightGBM, KNN) son insensibles a la transformación.